

基于转置卷积神经网络的隧道火灾烟气层高度和逆流长度快速预测模型^{*}

何志平¹, 洪瑶², 陈佟越¹, 李建²

(1.广州地铁集团有限公司, 广东 广州 510330;

2.中国安全生产科学研究院, 北京 100012)

摘要:为解决隧道火灾中所产生有害烟气的高度分布和逆流长度的预测问题,基于转置卷积神经网络模型构建用于瞬时快速预测烟气分布和逆流长度的计算模型,给出数据处理的细节方法和损失函数,并通过数值数据库训练评估所提模型。研究结果表明:经过400个训练周期,训练集和测试集中的损失函数均趋于收敛,所提模型较好地捕捉到了烟气可见度物理场中的主要特征和细节;模型训练完毕后,在测试集的验证过程中取得了较好的结果,烟气层高度沿纵向分布的预测结果误差 ± 0.5 m的频率不超过20%,烟气逆流长度的预测基本在20%相对误差限内。研究结果可为隧道火灾烟气层分布规律的快速预测提供参考。

关键词:隧道火灾;转置神经网络;烟气层高度;逆流长度

中图分类号:X932

文献标志码:A

文章编号:1673-193X(2025)-09-0063-06

A fast prediction model for smoke layer height and back-layering length in tunnel fire based on transposed convolutional neural network

HE Zhiping¹, HONG Yao², CHEN Tongyue¹, LI Jian²

(1.Guangzhou Metro Group Co., Ltd., Guangzhou Guangdong 510330, China;

2.China Academy of Safety Science and Technology, Beijing 100012, China)

Abstract: In order to address the prediction problem of harmful smoke layer height distribution and back-layering length in tunnel fires, a computational model based on a transposed convolutional neural network was developed for rapid instantaneous prediction of smoke dispersion and back-layering length. Detailed methods for data processing and loss functions were provided, and the proposed model was trained and evaluated using a numerical database. The results demonstrate that after 400 training epochs, the loss functions in both the training and testing sets tend to converge. The proposed model effectively captures the main features and details in the physical field of smoke visibility well. After model training was completed, the model achieved satisfactory performance during the validation process on the testing set. The error in predicting the longitudinal distribution of smoke layer height is within ± 0.5 m for no more than 20% of the cases, and the predictions for smoke back-layering length is mostly within a 20% relative error limit. These findings provide a valuable reference for the rapid prediction of smoke layer distribution patterns in tunnel fires.

Key words: tunnel fire; transposed neural network; smoke layer height; back-layering length

0 引言

隧道在地下空间利用和交通线路优化中扮演着关

键角色,但其运营安全始终面临严峻挑战,火灾等灾害难以完全避免^[1-5]。其中,隧道火灾因空间受限,产生的热烟气及有毒物质极易积聚且难以排出,加之内部人

收稿日期:2024-06-07

^{*} 基金项目:“十四五”国家重点研发计划项目(2023YFC3010205);北京市科技新星计划项目(20220484050,20230484417);中国安全生产科学研究院基本科研业务费专项资金项目(2024JBKY02)

作者简介:何志平,本科,高级工程师,主要研究方向为城际铁路安全。

通信作者:洪瑶,博士,工程师,主要研究方向为火灾动力学。

员、车辆密集,极易引发重大伤亡事故,造成恶劣社会影响。因此,为有效降低火灾烟气危害,深入探究烟气在热浮力、通风等作用下的演化机制与分布规律具有重要的现实意义。

因此,学者们对机械通风条件下隧道火灾演化规律进行了广泛的讨论和研究^[6-9]。Chow^[10]研究纵向通风作用下隧道火灾烟气的蔓延情况,并通过数据拟合给出了临界速度的计算关联式。Li 等^[11]研究了隧道坡度对烟气蔓延分布规律的影响,并给出了逆流长度的计算关联式。Ji 等^[12]通过研究隧道高度和宽度对隧道火灾烟气分布的影响规律,给出了与横截面长高比有关的比例因子,用于修正一般情况下临界通风速度和逆流长度的计算关联式。Zhang 等^[13]进一步扩充了实验条件范围,获得了超大宽高比隧道火灾临界速度关联式。Weng 等^[14]通过引入水力直径代替隧道高度,通过少量小火实验得到临界速度关联式。Chen 等^[15]研究了下游具有单个横向抽风口的由纵向通风主导的隧道火灾,并得到临界速度关联式。Hu 等^[16]通过分析天花板下温度分布,并通过理论分析得到临界速度估计方程。然而,计算关联式往往只能估算烟气层的高度,未能详细给出烟气沿着隧道纵向的整体分布规律,也无法给出大致的物理图像。近年来,也有学者使用人工智能的方法研究隧道火灾中的一般规律。Zhang 等^[17]通过整合大量实验数据,使用全连接神经网络模型拟合实验数据,得到了用于预测隧道火灾临界速度和烟气逆流长度的快速预测模型。Hong 等^[18]则使用大型数值数据库和机器学习模型预测了烟气逆流长度,并给出了不同机器学习模型优劣性的对比结果。上述研究为隧道火灾烟气的分布规律研究提供了便捷方法。

然而,目前已有的实验关联式模型和所应用的人工智能模型,都无法同时直接给出预测烟气层高度分布、烟气逆流长度以及烟气可见度场,无法为隧道消防系统的设计和安全事故的调查提供充足的物理数据信息。本文基于转置神经网络模型改进现有的预测方法,提出可用于预测烟气层高度分布、烟气逆流长度以及烟气可见度场的人工智能模型。模型的优势在于给出隧道火灾的一些关键物理参数后,可实现烟气分布信息的瞬时预测,为隧道火灾烟气蔓延规律及消防设计的研究提供参考。

1 场景与预测方法

1.1 场景和数据

隧道的尺寸为 $H \text{ m} \times W \text{ m} \times 60 \text{ m}$,隧道火灾场景如图 1 所示。假设隧道没有分叉,墙壁沿着 x, y 和 z 轴没有弯曲。假定隧道配备纵向通风系统,且无横向通风系统。隧道高度(H)、宽度(W)、倾斜角度(θ)、火源功率

($\dot{Q}$)、环境温度(T_{∞})和通风速度(v_0)为控制隧道火灾发展的未知关键参量。假定隧道的墙壁是由混凝土组成的。假设火源发生在隧道底部中心,其中火源的燃烧面积为 1.0 m^2 。丙烷为唯一燃料,一氧化碳的质量产率假设为 0.01 kg/kg ,烟气的质量产率假定为 0.037 kg/kg 。入口边界条件为 v_0 均匀分布速度入口,出口设为恒定动压。数值模拟的推进时间为 300 s 。




图 1 隧道火灾场景示意

Fig.1 Schematic of tunnel fire scenarios

本文研究所用数据集为文献[18]中的数据集,该数据集基于 FDS^[19]采用高分辨率数值模拟手段获取,数据经过网格无关性验证和实验验证,可靠性强。数据集包含 1 000 组不同隧道火灾场景,关键参量变化范围如表 1 所示。表 1 中所列关键参量变化范围偏小,实际问题应更细致考虑。本文所采用的数据包括可见度场图片(颜色栏上下限固定)及其 6 项对应的控制参量,记为 $S = \{x, z\}$, x 为可见度场, $z = (H, W, T_{\infty}, \theta, \dot{Q}, v_0)$ 。1 000 个样本中,70%样本为^[20]训练集,剩余 30%为测试集。

表 1 数据集关键参量的变化范围

Table 1 Variation range of key parameters in the dataset

关键参量	变化范围	单位
H	{2, 2.5, 3, 3.5, 4}	m
W	[3, 3.5, 4, 4.5, 5]	m
T_{∞}	[10, 30]	℃
θ	[-15, 15]	(°)
$\dot{Q}$	[0.35, 5]	MW
v_0	[0.2, 5]	m/s

1.2 数据预处理

由于隧道截面尺寸、倾斜角度均不一致,有必要对可见度场进行相应的数据处理,使模型输出像素点大小一致,具体处理过程如图 2 所示。分别对场图进行时间平均、旋转、缩放以及归一化操作,最后可见度场变为分辨率(80×3 200) px 的矩形 RGB 三通道图像,并且每个像素点数值大小在[-1, 1]区间内。同理,如图 2 所示,6 项关键参量按照最大最小归一化的方式将其范围控制在[0, 1]之间,模型推理所得可见度场经过图像反归一化等操作还原,最终用于分析烟气层高度和逆流长度等信息。




图2 数据处理细节示意

Fig.2 Schematic of data processing details

1.3 深度学习模型的构建

本文提出的深度学习网络模型如图3所示,该网络

模型基于转置神经网络进行的改进,包含了4个全连接层、4个上采样层以及3个残差块层,最终形成从关键参量预测能见度场的推理过程,推理结果与实际结果之间的差异构成损失函数。顺着推理计算的方向,卷积核大小、步幅以及其他相关信息如图3所示。网络结构中的残差块^[21]为1个小的神经网络模块,依次为1项卷积核大小为 3×3 的卷积层(输出通道数等于输入通道数)、 $ReLU$ 激活函数层^[22]、1项卷积核大小为 3×3 的卷积层(输出通道数等于输入通道数)、1层叠加层以及 $ReLU$ 激活函数层。

网络的损失函数(L)是原始场信息与预测场信息间的差异,其计算如式(1)所示:

$$L = \frac{1}{3N} \sum_{c=1}^3 \sum_{n=1}^N (x_{c,n} - x'_{c,n})^2 \quad (1)$$

式中: $x_{c,n}$ 是原始场图中第 c 个通道中第 n 个像素点的值; $x'_{c,n}$ 是预测场图中第 c 个通道中第 n 个像素点的值; c 是通道编号; n 是像素点编号; N 是像素总数。输出图像是RGB三通格式,像素尺寸为 (80×3200) px。




图3 隧道火灾烟气深度学习网络模型结构

Fig.3 Structure of the deep learning network model for tunnel fire smoke

模型训练的批尺寸大小为8,使用Adam^[20]参数优化求解器($\beta_1 = 0.9, \beta_2 = 0.999$),所采用的学习率是 1.5×10^{-4} ,训练周期Epoch最大为500。

2 结果分析与讨论

2.1 模型训练过程分析

模型训练过程中,损失函数随训练周期的演化情况

如图4所示。由图4可知,损失函数在前40个周期内下降较为迅速,在第40个训练周期附近达到近似收敛的结果,随后在整体上呈现出逐渐减小的趋势。该结果表明模型的训练朝着收敛的方向进行,没有出现梯度爆炸等情况,数据的内蕴关系被模型所吸收。此外,训练集的损失函数(L)在20个训练周期后就明显低于测试集的损失函数(L_{test}),其中训练集的损失函数在100个

训练周期后小于 1, 而测试集的损失函数则明显大于 1。该结果表明模型的训练出现了过拟合现象, 尽管过拟合的程度相对较小, 但仍需要进一步通过预测结果来评估模型的预测能力。




图 4 训练过程损失函数的演化曲线

Fig.4 Evolution curve of loss function values during training process

图 5 绘制了训练过程中经过 6 个关键参数作为模型的输入, 最终推理所得到的烟气可见度场。由图 5 可知, 未经训练的模型 ($Epoch=0$) 推理所得的可见度场基本不包含任何信息, 说明模型此时不具备任何推理能力。经过 10 个训练周期, 模型已经具有大致的推理能力, 但无论是烟气的分布形态和颜色细节都和实际的可见度场存在差异。第 50 至 100 个训练周期, 可以看到模型的推理能力逐渐增强, 仅有部分细节未能完全推理, 颜色细节方面已经和实际可见度场较为接近。训练至 400 个训练周期时, 模型便已经具备较强的推理能力, 在烟气形态捕捉方面表现良好, 除了部分可见度低的区域被过高地预测外 (如图 5(e) ~ 图 5(f) 所示, 绝对误差约为 2.5 m), 色彩细节捕捉也相对良好, 推理结果和实际可见度场保持较为一致的结果。

综上所述, 模型经过 50 个训练周期后初步具备推理能力, 但仍需持续微调改进, 直至 400 个训练周期, 模型具备较为完备的推理能力。然而, 模型仍需要从测试集的角度进一步探究其泛化的预测能力。




图 5 训练过程中可见度场的预测结果演化情况

Fig.5 Evolution of predicted visibility fields during training process

2.2 模型预测能力评估及分析

为评估模型的预测能力, 主要从烟气层高度、烟气逆流长度以及整个可见度场 3 个方面进行考察。图 6 为从测试集中任意选取 1 项案例烟气层高度的预测性能的评估结果。由图 6 可以看出, 预测的可见度场和真

实可见度场在颜色上存在差异, 但是烟气层高度的分布差异非常小。图 7 是 300 个测试集中所有实际烟气层高度分布和预测烟气层高度作差后的绝对误差统计图, 可以看到接近 80% 的绝对误差在 0 附近, ± 0.5 m 绝对误差的结果低于 20%, 表示本文所提出的预测模型对于烟

气层高度分布的快速预测具有较好的性能。




图6 烟气层高度的预测性能评估结果

Fig.6 Evaluation results of prediction performance for smoke layer height




图7 实际和预测烟气层高度差的分布结果

Fig.7 Distribution results of difference between actual and predicted height of smoke layer

图8为烟气逆流长度的预测性能评估结果,其中图8(e)中上游的计算所得的第1个拐点位置计算如式(2)所示,该位置被认为是烟气逆流的锋面位置。

$$x_L = \arcsin \left(\frac{\partial h(x)}{\partial x} < 0 \right) \quad (2)$$

式中: x_L 为锋面坐标; x 表示隧道纵向坐标轴; $h(x)$ 表示烟气层高度。锋面至火源位置的长度 $-x_L$ 即为逆流长度。通过对比实际可见度场和预测可见度场中的逆

流长度可用于评估模型对于逆流长度的预测性能。图9为实际和预测逆流长度对比结果,可以看到300个测试集中,大部分的预测结果都在20%的相对误差限内,表明模型对于烟气逆流长度的预测能力良好。




图8 烟气逆流长度的预测性能评估结果

Fig.8 Evaluation results of prediction performance for smoke back-layering length




图9 实际和预测逆流长度的对比结果

Fig.9 Comparison results of actual and predicted smoke back-layering length

3 结论

1)提出了基于转置卷积神经网络的深度学习模型,用于输入关键物理参数来快速预测隧道火灾烟气层高度分布规律和烟气逆流长度,给出了数据处理方法和训

练参数,便于针对此类问题的快速求解。

2) 分析了模型的收敛性和训练过程,确定了训练过程中模型在各训练周期中的表现的推理特征:从初始无任何推理能力到具有图形概括能力,再到具备基本轮廓预测能力,最后到细节预测能力并完成训练。

3) 评估了模型的预测能力,分别对可见度场、烟气层高度沿隧道纵向的分布规律以及烟气逆流长度 3 个方面进行了分析,结果表明模型在测试集上较好地复现了实际的可见度场;较好预测了烟气层高度的分布,±0.5 m 的绝对误差不超过 20%;较好预测了烟气逆流长度,大部分结果均在 20% 的相对误差限内。

参考文献

- [1] 陈长坤,王玮玉,康恒,等.不同火源面积下隧道火灾温度场试验与数值模拟分析[J].中国公路学报,2018,31(6):235-243.
CHEN Changkun, WANG Weiyu, KANG Heng, et al. Experimental and numerical simulation analysis of temperature field of tunnel fire with different fire source areas[J]. China Journal of Highway and Transport, 2018, 31(6): 235-243.
- [2] 胡隆华.隧道火灾烟气蔓延的热物理特性研究[D].合肥:中国科学技术大学,2006.
- [3] ALAN B, RICHARD C. Handbook of tunnel fire safety[M]. ICE publishing, 2012.
- [4] CARVEL R. A review of tunnel fire research from Edinburgh[J]. Fire Safety Journal, 2019, 105: 300-306.
- [5] HONG Y, FU C. A full-range analytical solution of the critical velocity for smoke control in tunnel fires[J]. Case Studies in Thermal Engineering, 2022, 40: 102531.
- [6] ÁLBAREZ C D, AYALA P, CANTIZANO A, et al. A coupled hybrid numerical study of tunnel longitudinal ventilation under fire conditions [J]. Case Studies in Thermal Engineering, 2022, 36: 102202.
- [7] CHEN K, ZHOU F, XIA T, et al. Ventilation network solution method based on coupling iteration of air state parameters and air quantity [J]. Journal of China University of Mining & Technology, 2021, 50(4): 613-623.
- [8] CHOW W K, WONG K Y, CHUNG W Y. Longitudinal ventilation for smoke control in a tilted tunnel by scale modeling[J]. Tunnelling and Underground Space Technology, 2010, 25(2): 122-128.
- [9] FAN C, ZHANG L, JIAO S, et al. Smoke spread characteristics inside a tunnel with natural ventilation under a strong environmental wind [J]. Tunnelling and Underground Space Technology, 2018, 82: 99-110.
- [10] CHOW W K. On smoke control for tunnels by longitudinal ventilation[J]. Tunnelling and Underground Space Technology, 1998, 13(3): 271-275.
- [11] LI J, LI Y, CHENG C, et al. A study on the effects of the slope on the critical velocity for longitudinal ventilation in tilted tunnels[J]. Tunnelling and Underground Space Technology, 2019, 89: 262-267.
- [12] JI J, HAN J Y, FAN C G, et al. Influence of cross-sectional area and aspect ratio of shaft on natural ventilation in urban road tunnel[J]. International Journal of Heat and Mass Transfer, 2013, 67: 420-431.
- [13] ZHANG T, WANG G, LI J, et al. Experimental study of back-layering length and critical velocity in longitudinally ventilated tunnel fire with various rectangular cross-sections[J]. Fire Safety Journal, 2021, 126: 103483.
- [14] WENG M C, LU X, LIU F, et al. Prediction of backlayering length and critical velocity in metro tunnel fires[J]. Tunnelling and Underground Space Technology, 2015, 47: 64-72.
- [15] CHEN L, HU L, ZHANG X, et al. Thermal buoyant smoke back-layering flow length in a longitudinal ventilated tunnel with ceiling extraction at difference distance from heat source[J]. Applied Thermal Engineering, 2015, 78: 129-135.
- [16] HU L, HUO R, CHOW W K, et al. Studies on buoyancy-driven back-layering flow in tunnel fires[J]. Experimental Thermal and Fluid Science, 2008, 32(8): 1468-1483.
- [17] ZHANG X, WU X, PARK Y, et al. Perspectives of big experimental database and artificial intelligence in tunnel fire research[J]. Tunnelling and Underground Space Technology, 2021, 108: 103691.
- [18] HONG Y, KANG J, FU C. Rapid prediction of mine tunnel fire smoke movement with machine learning and supercomputing techniques[J]. Fire Safety Journal, 2021, 127: 103492.
- [19] MCGRATTAN K, HOSTIKKA S, FLOYD J, et al. Fire dynamics simulator technical reference guide volume 1: mathematical model [M]. NIST Special Publication, 2021.
- [20] PASZKE A, GROSS S, MASSA F, et al. PyTorch: an imperative style, high-performance deep learning library[C]//32nd Conference Neural Information Processing Systems, 2019.
- [21] ZHANG K, SUN M, HAN T X, et al. Residual networks of residual networks; multilevel residual networks[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2017, 28(6): 1303-1314.
- [22] XU J, LI Z, DU B, et al. Reluplex made more practical: Leaky ReLU [C]. Proceedings-IEEE Symposium on Computers and communications, 2020.

(责任编辑:张丽芳)